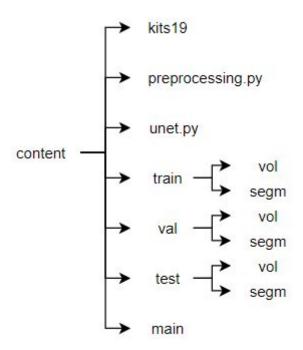
Raport 08.06.2020 r.

1. Wykonane zadania

- 1. Charakterystyka zbioru danych podział na zbiór treningowy i testowy, format danych, wymiary zdjęć
- 2. Preprocessing
- 3. Zaimplementowanie architektury U-net
- 4. Implementacja walidacji DICE.

2. Przygotowanie danych

Opracowano strukturę danych:



Preprocessing obejmuje przeskalowanie obrazów do rozmiatu 256 × 256, normalizację obrazów volume, zapisanie segmentacji w notacji one-hot oraz odpowiednie przygotowanie generatora danych (funkcja ImageDataGenerator).

3. Architektura

Do wykonania projektu, wykorzystano algorytm U-Net, która łączy warstwy enkodera z mapami obiektów dekodera tworząc strukturę przypominającą literę U. Cechą szczególną tej sieci jest to, że na każdym etapie umożliwia na zapoznanie się z cechami, które zostały utracone w wyniku działania warstwy łaczącej.

Wymiary obrazu wejściowego: 256 × 256 × 1

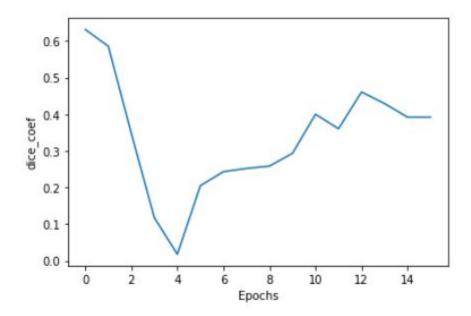
```
Contracting path: Conv2D → Dropout → Conv2D → MaxPooling2D
Expansive path: Conv2DTranspose → concatenate → Conv2D → Dropout
→ Conv2D
```

Jako funkcję utraty zastosowano *dice_coef_loss*, a wykorzystanym optimizer'em jest optimizer *adam*.

4. Efekt pracy i napotkane problemy

Wstępną segmentację przeprowadzono na zbiorze treningowym składającym się z 10 case'ów oraz zbiorze walidacyjnym z 5 case'ów. Wstępną ilością epok było 25, ale użycie EarlyStopping przerywa uczenie się sieci gdy wartość współczynnika spada.

Poniżej przedstawiono wykres wartości współczynnika DICE w zależności od epoki.



Niestety wyniki nie są wiarygodne - wiąże się to z potrzebą dostosowania funkcji współczynnika DICE do obecnego rozwiązania. Należy przyjrzeć się obliczaniu przez tę funkcję wartości dla notacji one-hot i ją dostosować.

Dalsze prace będą obejmowały:

- bugfix funkcji dice coef()
- test na nowym zbiorze danych
- optymalizacja uczenia sieci
- optymalizacja wyników
- wizualizację wyników
- sporządzenie raportu